

多说话人语音转写与多维智能检索系统

Multi-Speaker Speech Transcription and
Multi-Dimensional Retrieval System

——基于 SOTA 预训练模型、LLM 后处理增强与 BGE-M3 复合检索——

Integrating SOTA Pre-trained Models, LLM Post-Processing
and BGE-M3 Multi-Dimensional Composite Retrieval

技术方案设计与系统实现

Technical Design and System Implementation

May 19, 2026

摘 要

本文设计并实现了一个面向多说话人场景的端到端语音转写与智能检索系统。系统以“SOTA 预训练模型 + 工程化管线组合 + LLM 语义增强 + 多维智能检索”为核心技术路线，集成了前端人声分离（Demucs htdemucs_ft）、说话人分割聚类（Pyannote 3.1）、语音识别与词级对齐（WhisperX）、大语言模型（LLM）三层语义后处理，以及基于 BGE-M3 的稠密 + 稀疏双模检索编码器五类核心能力。针对说话人分离与语音识别两个模块因独立 VAD（语音活动检测）策略产生的跨模块时间戳漂移这一关键问题，本文提出了基于 VAD 逻辑 AND 交集的时间戳对齐方法——将两个模块各自 VAD 的输出取交集，仅保留双方共同标记为语音的时间区间，以几乎为零的计算代价有效消除了时序错位。在 LLM 后处理方面，系统设计了覆盖上下文驱动 ASR 纠错、说话人一致性交叉验证和 12 类对话行为意图多标签标注的统一三层架构，通过抽象适配器接口支持 DeepSeek、Claude 和 MiniMax 三种 LLM 后端的动态切换，单次 30 秒音频的 LLM 处理成本仅为 ¥0.002。在检索方面，系统基于纯 Transformer 库实现 BGE-M3 的 1024 维 CLS 稠密向量编码和 sparse_linear 稀疏词权重编码，结合 FAISS 内积索引和 Reciprocal Rank Fusion (RRF) 排序融合算法，构建了覆盖语义、关键词、说话人、时间和意图五个维度的复合检索框架，平均查询延迟为 38.3 毫秒。

实验在 AISHELL-4 中文会议数据集（20 个测试文件，各截取前 60 秒）上展开，以说话人分离错误率（DER）、字符错误率（CER）和检索延迟为核心评估指标。基线管线（无 LLM 后处理）的平均 DER 为 45.56%（collar=0.25s 容差下为 42.15%），完整管线（含 LLM 后处理）的 CER 为 58.80%，相比基线（59.03%）降低了 0.23 个百分点。检索系统在 5 段文本上的索引构建时间为 0.29 秒，平均查询延迟均在 90 毫秒以内，完全满足交互式应用的实时性要求。系统提供了基于 Gradio 的交互式图形界面，支持文件转写、浏览器端实时麦克风流式转录和自然语言驱动的多维复合检索三大功能，具备从本地 RTX 4060（8 GB 显存）工作站到 Cloud Studio T4（16 GB 显存）云端的双模式部署能力。

关键词：多说话人语音转写；说话人分离；自动语音识别；大语言模型后处理；多维检索；时间戳对齐；WhisperX；Pyannote；BGE-M3；Reciprocal Rank Fusion

Abstract

This paper presents the technical design and system implementation of an end-to-end multi-speaker speech transcription and intelligent retrieval system. Following the core technical route of “SOTA pre-trained models + engineering pipeline composition + LLM semantic enhancement + multi-dimensional intelligent retrieval,” the system integrates five core capabilities: front-end vocal separation (Demucs htdemucs_ft), speaker diarization (Pyannote 3.1), ASR with word-level forced alignment (WhisperX), large language model (LLM) three-layer post-processing, and BGE-M3-based dense-plus-sparse dual-mode retrieval encoding. To address the critical problem of cross-module timestamp drift caused by independent voice activity detection (VAD) strategies in the diarization and ASR modules, this paper proposes a VAD logical-AND intersection alignment method that preserves only temporal regions where both VADs agree on speech presence, effectively eliminating misalignment at near-zero computational cost. For LLM post-processing, a unified three-layer architecture is designed, covering context-driven ASR error correction, speaker identity cross-verification, and 12-class dialogue act multi-label intent tagging. An abstract adapter interface enables dynamic switching among DeepSeek, Claude, and MiniMax LLM backends, with a processing cost of only ¥0.002 per 30-second audio segment. For retrieval, the system implements BGE-M3’s 1024-dimensional CLS dense embedding and sparse_linear lexical weight encoding using only the Transformers library, combined with FAISS inner-product indexing and Reciprocal Rank Fusion (RRF), constructing a five-dimensional composite retrieval framework spanning semantic similarity, keyword matching, speaker identity, temporal range, and dialogue intent. The average query latency is 38.3 milliseconds.

Experiments are conducted on the AISHELL-4 Chinese conference dataset (20 test files, each truncated to the first 60 seconds), evaluated using Diarization Error Rate (DER), Character Error Rate (CER), and retrieval latency as primary metrics. The baseline pipeline (without LLM post-processing) achieves an average DER of 45.56% (42.15% with a 0.25-second collar tolerance), while the full pipeline (with LLM post-processing) achieves a CER of 58.80%, a 0.23 percentage-point reduction from the baseline of 59.03%. The retrieval system builds a FAISS index over 5 text segments in 0.29 seconds, with all query latencies under 90 milliseconds, fully meeting the real-time requirements of interactive applications. The system provides an interactive Gradio-based graphical user interface supporting file transcription, browser-based real-time microphone streaming transcription, and natural-language-driven multi-dimensional composite retrieval, with dual-mode deployment capability from a local RTX

4060 (8 GB VRAM) workstation to a Cloud Studio T4 (16 GB VRAM) cloud environment.

Keywords: Multi-Speaker Speech Transcription; Speaker Diarization; Automatic Speech Recognition; LLM Post-Processing; Multi-Dimensional Retrieval; Timestamp Alignment; WhisperX; Pyannote; BGE-M3; Reciprocal Rank Fusion

1 引言

1.1 研究背景与问题定义

在会议转录、影视字幕生成、庭审记录、在线教育录播和远程协作等真实场景中，语音信号具有三个核心特征：一是存在多个说话人交叉发言，二是有背景音乐（BGM）或环境噪声干扰，三是说话人之间的对话在语义上相互关联。传统的自动语音识别系统（ASR）将音频转录为纯文本序列，仅回答音频中“说了什么”的问题，却无法回答“谁在什么时候说了什么”这一对后续分析和应用至关重要的多维度问题 [1]。更进一步，当用户希望从大量会议或影视记录中高效检索特定信息时，传统的关键词搜索无法满足“找出 Speaker B 在后半段提出的所有反对意见”这类融合说话人身份、时间范围、语义内容和对话意图的复合查询需求。这一能力缺口阻碍了语音分析系统从“转录工具”向“智能理解平台”的演进。

近年来，以 Transformer 架构 [2] 为核心的深度学习模型在语音处理和自然语言处理两个领域分别取得了突破性进展。在语音识别方面，OpenAI Whisper 系列 [1] 在 68 万小时多语言弱监督数据上的训练展现了令人瞩目的零样本跨语言 ASR 能力；在说话人分离方面，Pyannote.audio 框架 [3, 4] 将端到端深度学习引入从语音检测到说话人聚类的每一环节；在文本处理方面，大语言模型表现出强大的上下文理解、语义推理和结构化信息提取能力，为 ASR 后处理和说话人标注的语义增强提供了全新的技术路径 [5]。

在上述技术进展的背景下，本文旨在回答一个具有工程实践价值的核心问题：能否仅利用公开可用的 SOTA 预训练模型，在不进行任何模型微调的前提下，通过精心设计的管线架构、跨模块对齐策略与 LLM 驱动的语义增强，构建一个完整、高效、多维可检索的多说话人语音转写系统？

1.2 系统面临的关键技术挑战

尽管 ASR、说话人分离和 LLM 各单模块的独立性能持续提升，将三者有机整合为一个协同工作的完整系统仍面临以下四项核心技术挑战：

挑战一：跨模块 VAD 时间戳漂移。Pyannote 与 WhisperX 各自内部使用不同的语音活动检测（VAD）模型——前者依赖自身 segmentation 模型的帧级语音概率阈值，后者使用独立的 Silero VAD[6]。两个 VAD 在语音边界的判据上存在系统性差异（Pyannote 对语音边界更敏感但虚警率略高，Silero 的边界判断更保守），导致直接合并两者的输出时产生严重的时序错配——说话人 A 的语音片段被错误分配到说话人 B 的时间区间内，使最终输出的“谁在什么时候说了什么”信息在说话人维度上高度不可靠。

挑战二：纯声学 ASR 的语义层误差。声学模型仅基于音频信号的底层频谱特征进行

转录，天然无法利用对话的语义上下文、领域先验知识和常识推理进行自纠错。同音字混淆（如“方案”与“方按”）、上下文矛盾（如说话人已明确表示同意，ASR 却将其后续发言转录为反对语义）和专有名词错识（人名、地名、专业术语）等典型错误在 ASR 输出中普遍存在并向下游传播，严重影响转写结果在实际应用中的可用性。

挑战三：说话人聚类的不完整性。说话人分离的聚类算法存在两类固有错误 [7]：过分割——同一位说话人被分配了多个不同的匿名 Speaker ID（通常因为说话人的音色、音量或语速在发言过程中发生了变化）；欠分割——两位不同说话人被合并到同一个 Speaker ID 之下（通常因为两人的音色特征相似或重叠发言时的嵌入提取出现混叠）。这两类错误直接损害“谁说了什么”的信息完整性，特别是当下游应用（如会议摘要、角色分析）严格依赖准确的说话人归属时。

挑战四：非结构化转写文本的多维检索。转写输出的 segments 是不带结构化元数据的纯文本序列。要实现“Speaker B 的后半段反对意见中涉及‘预算’的发言”这类五维约束的复合查询，需要一个能够同时编码语义相似度、词法匹配、说话人身份过滤、时间范围约束和意图类别匹配的统一检索框架，且各维度的得分需要经过合适的融合机制产生最终的排序结果。

1.3 本文的技术路线与核心贡献

针对上述四项挑战，本文采用的技术路线可概括为：SOTA 预训练模型 + 工程化管线组合 + LLM 语义增强 + 多维智能检索。核心原则是不进行任何模型微调，所有性能提升来源于管线架构设计、模块间对齐策略和 LLM 驱动的语义后处理。本文的主要贡献为：

- (1) 设计并实现了六阶段模块化管线架构，将 Demucs 前端分离、Pyannote 3.1 说话人分离、WhisperX 语音识别与强制对齐、LLM 三层语义后处理和 BGE-M3 多维检索索引构建有机集成。针对 Windows + CUDA 12.4 的平台特定挑战，通过 CUDA DLL 路径注册、音频库导入顺序控制和 GPU 显存逐阶段主动释放等工程手段，将本地 RTX 4060（8 GB VRAM）的峰值显存控制在 4 GB 以内，云端 T4（16 GB VRAM）控制在 8 GB 以内。
- (2) 提出了 VAD 逻辑 AND 交集的时间戳对齐方法，以 <0.1 秒的计算代价有效解决了说话人分离与 ASR 模块之间的跨模块时间戳漂移问题，确保最终输出的说话人标签与 ASR 文本在时序上精确对齐。
- (3) 设计了 LLM 三层语义后处理架构：(a) 基于对话上下文的 ASR 同音字和语义矛盾修正；(b) 基于说话风格和内容主题一致性的说话人过分割/欠分割检测与自动合并；(c) 基于 12 类对话行为意图标签体系的多标签标注。通过统一的适配器模式支持多 LLM 后端的动态切换，后处理成本极低（¥0.002/30 秒音频）。
- (4) 基于纯 Transformer 库实现了 BGE-M3 的稠密向量编码（1024 维 CLS token）和稀疏词权重编码（sparse_linear 层），结合 FAISS 索引和 RRF 排序融合机制，

构建了覆盖语义、关键词、说话人、时间和意图五个维度的复合检索系统，查询延迟均在 100 毫秒以内。

2 国内外研究现状

2.1 自动语音识别技术演进

2.1.1 国际研究进展

自动语音识别领域在过去十年间经历了从 GMM-HMM 统计建模到端到端深度学习的完整范式转移。早期的深度 ASR 系统（如 DeepSpeech 系列）使用基于连接时序分类（CTC）的序列转导模型，在数万小时标注数据上训练后取得接近人类的英文识别精度。2017 年 Transformer 架构 [2] 的提出深刻改变了 ASR 的技术方向：相比 RNN/LSTM，Transformer 的全局自注意力机制天然适合序列转导任务中的长程时序依赖建模，且更易于并行化训练。

Conformer[8] 将卷积模块嵌入 Transformer 的自注意力层之间，通过卷积捕获局部频谱特征，通过自注意力捕获全局时序上下文，二者的协同使模型在多项 ASR 基准上超越了纯 Transformer 架构。Conformer 也成为了后续 Whisper 等大模型 ASR 系统编码器端的事实标准。

2022 年，OpenAI 发布了 Whisper 系列模型 [1]，这是 ASR 领域的标志性事件。Whisper 采用标准的 Transformer 编码器-解码器架构，在 68 万小时的互联网多语言弱监督音频数据上进行多任务学习（同时学习转录、翻译、语种识别和时间戳生成四类任务），覆盖 99 种语言。其关键创新在于训练数据的来源与规模——通过从互联网收集海量多语种音频及对应的自动对齐文本，Whisper 在不使用任何人工精标数据的情况下，学到了强大的跨语种零样本 ASR 能力，在许多语言上的 zero-shot 转录精度甚至超过该语言上全监督训练的传统模型。这一结果从根本上改变了 ASR 领域的“数据-性能”关系认知：大规模弱监督数据可以在一定程度上替代小规模精标数据的不足。

在 Whisper 的生态迭代方面，WhisperX[6] 解决了 Whisper 的两个输出限制：(1) 引入基于 wav2vec2[9] 的强制对齐（forced alignment），将 Whisper 输出的话语级粗粒度时间戳细化至词级；(2) 利用 Silero VAD 进行 VAD 预处理以精确定位语音段边界，替代 Whisper 内部相对简单的语音检测；(3) 支持 beam search 的 N-best 候选列表输出。这些改进使 WhisperX 成为多说话人语音转写管线中事实上的标准 ASR 模块。faster-whisper 项目通过 CTranslate2 推理引擎对 Whisper 进行了计算优化，在保持输出质量不变的同时将推理速度提升约 4 倍，但在 Windows CUDA 环境下对 cuDNN DLL 的路径依赖增加了部署复杂度。

Whisper-AT[10] 的消融实验进一步揭示了 Whisper 编码器学习的声学表征具有高

度的通用性和下游可迁移性——一个未经过额外训练的 Whisper 编码器，在通用音频事件标签任务上的 zero-shot 表现可以超越许多专用音频标签系统。这一发现间接支持了本系统的技术路线选择：利用 Whisper 的通用预训练声学表征，叠加轻量级的对齐和重打分后处理，即可在零样本条件下获得实用的 ASR 性能，而无需为领域特定数据微调模型。

2.1.2 国内研究进展

在国内 ASR 研究方面，中文语音识别因其声调语言的特性和大规模方言变体的存在而面临独特挑战。WenetSpeech[11] 是国内首个超过 10,000 小时的中文语音开源数据集，覆盖互联网、会议、阅读、电话等多个领域场景。该数据集的发布标志着中文 ASR 研究从“小规模标准数据集”向“大规模领域多样化数据集”的转向，为中文 ASR 的工业级模型训练提供了数据基础。

在模型架构方面，Gao 等人 [12] 研究了混合 CTC/注意力架构在中文 ASR 中的应用，证明 CTC 分支在中文这种以单音节为基本单元的语言中对强制对齐精度有独特帮助（中文的字符边界在声学上比英文的单词边界更难界定）。Fan 等人 [13] 提出了门控循环融合和多任务联合训练框架，在中文端到端 ASR 中结合了声学建模和语言建模的联合优化，在 AISHELL 系列基准上取得了当时的领先结果。在外场（远场）场景下，国内研究重点关注麦克风阵列信号处理和通道融合策略。多通道多说话人 ASR 系统 [14] 通过目标说话人 ASR 技术，将阵列波束形成与神经 ASR 的联合训练相结合，在远场会议场景中取得了优于传统“波束形成 + 单通道 ASR”级联方案的性能。

2.2 说话人分割聚类技术演进

2.2.1 国际研究进展

Speaker Diarization（说话人分割聚类）解决的是“谁在什么时候说话”的核心问题。传统方法（以 Kaldi x-vector + PLDA 管线为代表）采用模块化设计：语音活动检测（VAD）→ 说话人嵌入提取（x-vector/i-vector）→ 概率线性判别分析（PLDA）评分 → 凝聚层次聚类，各步骤依赖手工声学特征和统计模型。Park 等人 [7] 在一篇系统综述性文献中全面地梳理了深度学习时代说话人分离技术的进展脉络——从 x-vector 到 d-vector 再到 ResNet-based 说话人嵌入，从 PLDA 到基于神经网络的相似度评分，以及端到端神经说话人分离（EEND）范式的出现。

Pyannote.audio[3, 4] 代表了说话人分离领域的深度学习模块化方案。其管线设计延续了传统模块化架构（分段 → 嵌入 → 聚类），但每一环节均用深度神经网络实现：(1) Segmentation 模型使用 SincNet 滤波器组和双向 LSTM 架构，以 10 秒滑窗在输入音频上逐帧预测说话人存在性概率，包括多说话人同时发声的 overlap 区域检测；(2) Embedding 模型基于 WeSpeaker[15] 的 ResNet-34 架构，输出 256 维固定长度

的说话人嵌入向量；(3) 聚类使用基于余弦距离的凝聚层次聚类。Pyannote 2.x 版本通过 onnxruntime 进行分段模型和嵌入模型的推理部署。Pyannote 3.1（2024 年发布）的标志性改进是完全移除了 onnxruntime 依赖，改为在原生 PyTorch 环境中进行全套推理，这极大地简化了跨平台（尤其是 Windows）的部署流程和版本兼容性管理。

2.2.2 国内研究进展

在国内研究方面，Huang 等人 [16] 对多种说话人分离方法在中文会议场景下的性能进行了系统的对比实验，评估了 Pyannote 3.1、基于 WeSpeaker 的聚类管线以及端到端神经 Diarization 方法在 AISHELL-4 和 AliMeeting 上的表现差异。其关键发现是：在中文场景下，WeSpeaker[15] 作为说话人嵌入模型普遍优于英文数据预训练的 ECAPA-TDNN 和 x-vector，因为 WeSpeaker 在大规模中文说话人数据上进行预训练，其嵌入空间对中文说话人（尤其是声调变化大的说话人）具有更好的区分度。WeSpeaker 本身来自上海交通大学的语音实验室，是国内说话人识别和嵌入领域的重要开源贡献。

Zhang 等人 [17] 提出了基于改进交叉注意力机制的目标说话人 VAD 方法，通过在多说话人混合音频中聚焦目标说话人的声纹特征来提高其在噪声和重叠语音中检测该说话人的准确率。该方法的思想——“在 VAD 时引入说话人嵌入作为条件信息”——与本系统中 LLM 一致性检查的原理有异曲同工之处，都是在说话人分离的边界检测中引入额外的身份信息进行辅助判断。

2.3 LLM 辅助语音后处理

2.3.1 国际研究进展

ICASSP 2024–2025 期间，LLM 辅助 ASR 后处理成为一个快速发展的研究方向。Chen 等人 [18] 在 LLM 用于语音和音频处理的综述文献中系统梳理了这一领域的三个主要范式：

(1) N-best 重打分：ASR 的 beam search 可以输出多个候选转录（N-best 列表）。传统方法使用外部 BERT 或 GPT-2 语言模型对各候选句的流畅度和可能性进行单句评分，LLM 版本的 N-best 重打分则将完整对话上下文一次性发送给 LLM，由 LLM 判断哪个候选句在给定对话流程的语义约束下最合理。在含同音字混淆的场景中（ASR 的多个候选对应不同的同音字），LLM 能利用上文的领域信息和下文的语义连贯性来进行消歧选择，效果远超单句语言模型。

(2) 上下文纠错：将完整段落的 ASR 转录直接交由 LLM 进行阅读和修正。LLM 基于对对话角色、讨论主题和上下文逻辑的理解，自主判断每句转录是否存在错误并提出修正意见。Wang 等人 [5] 的研究表明，在中文会议场景中，LLM 上下文纠错特别善于

修正三类错误：同音字混淆（如“代驾”→“代价”）、数字序列（如电话号码、金额）的 ASR 错误，以及上下文语义矛盾（当前发言与之前已明确的立场或事实不一致）。

(3) 对话行为标注：对话行为（Dialogue Act）标注的历史可追溯到 Stolcke 等人 [19] 的经典工作——使用 HMM 和决策树对 Switchboard 电话对话进行 42 类对话行为的自动标注。LLM 的出现使零样本对话行为标注成为可能——通过详细的提示定义，LLM 可以在没有任何标注训练数据的情况下直接为发言赋予多标签意图，且标注质量经评估达到了与微调 BERT 模型可比的水平 [20]。

2.3.2 国内研究进展

在国内，LLM 辅助语音处理的研究侧重于中文特有的挑战。由于中文没有明确的词边界（与英文天然的空格分词不同），ASR 处理以字（character）为基本单元，因此在 CER 上的纠错粒度与英文的 WER 维度不同——中文 LLM 后处理需要同时考虑单字错误和整词错误两个粒度的纠正。同时，中文存在大量同音字（据估计，汉语普通话中平均每个音节对应约 10 个常用汉字），这对 LLM 的消歧能力提出了更高的要求。

2.4 文本嵌入与跨模态检索

文本嵌入模型经历了从静态词向量（Word2Vec, GloVe）到上下文预训练向量（BERT, RoBERTa[21]）再到多功能多语言嵌入模型的演进。Sentence-BERT[22] 引入孪生网络结构和对比学习损失，使 BERT 类模型能够输出语义上有意义的定长句子向量，奠定了现代语义检索的技术基础。

BGE-M3[23]（BAAI General Embedding M3，2024 年发布）是多语言多功能嵌入模型的最新代表。其核心创新在于一个模型同时支持三种互补的文本表示：(1) 稠密向量（Dense Embedding，1024 维）——基于 XLMRobertaModel 基座，取 CLS token 的最后一层隐藏状态经 L2 归一化得到，用于基于余弦相似度的高效语义检索；(2) 稀疏词权重（Sparse/Lexical Weights）——通过单独的轻量级 sparse_linear 层（ $\mathbb{R}^{1024} \rightarrow \mathbb{R}$ ）从每 token 隐藏状态计算 token 级重要性分数，经 ReLU 激活后过滤，提供原生的 BM25-like 词法关键词检索能力；(3) 多向量表示（ColBERT）——查询和文档的每 token 分别编码后进行延迟交互匹配，精度高但延迟也高。BGE-M3 覆盖 100 余种语言，在中英文混合场景下经自知识蒸馏训练后表现稳定。

在排序融合方面，Reciprocal Rank Fusion (RRF) [24] 自 2009 年提出以来，在信息检索、推荐系统和多路召回融合领域得到了广泛应用。其核心公式为 $RRF_score(d) = \sum_{r \in R} \frac{w_r}{k + \text{rank}_r(d)}$ （ k 为平滑常数，通常取 60），RRF 的核心优势在于不需要对各维度的原始得分进行归一化处理，仅依赖排序位置进行融合，因此对不同得分尺度的异构检索维度具有天然的鲁棒性。

2.5 音频前端音源分离

在影视和音乐等含有背景音乐的音频场景中，BGM 对后续 ASR 和说话人分离构成严重的加性噪声干扰。Demucs[25, 26] 由 Meta AI 开发，是一套基于深度学习的开源源分离系统。其 htdemucs_ft 版本采用混合时域/频域 Transformer 架构——编码器在时域和频域两个并行的卷积分支上分别提取信号特征，在瓶颈层通过跨域注意力机制（cross-domain attention）进行时频特征融合，解码器通过 U-Net 风格的跳跃连接恢复分离后的各音轨波形。模型在大规模多轨音乐数据集上训练，经过广泛的随机数据增强训练后获得了强的泛化分离能力。

2.6 本节小结

综合以上国内外研究现状的分析，可以看到三个关键趋势：(1) 大规模预训练模型成为各模块的基础，微调的必要性正在降低；(2) LLM 正在从单纯的 NLP 模型演化为通用的语义推理组件，可被嵌入各种传统管线中进行语义增强；(3) 多功能模型（一个模型支持多种输出表示）正在取代单功能模型，降低了管线复杂度。本研究充分借鉴这些趋势，形成了“不微调、重管线、LLM 增强”的技术路线。

3 系统设计

3.1 总体架构

系统采用六阶段模块化管线架构，各阶段严格按序执行，阶段之间通过 GPU 显存的主动回收实现资源安全隔离。整体数据流为：

Stage 1: 人声分离（可选，影视/音乐场景）：使用 Demucs htdemucs_ft 模型将混合音频分离为人声轨和伴奏轨，仅将 16 kHz 单声道的人声轨送入后续处理管线。在会议录音（无 BGM）场景下可跳过此阶段以节省约 2 GB 显存。

Stage 2: 说话人分离：对音频执行 Pyannote 3.1 的标准管线——Segmentation 模型以 10 秒滑窗逐帧检测语音活动概率和各说话人存在性 → WeSpeaker ResNet-34 嵌入模型为各语音段提取 256 维说话人嵌入 → 凝聚层次聚类将嵌入分组为说话人。输出为标准 RTTM 格式的时间段-说话人标注。

Stage 3: 语音识别与强制对齐：WhisperX 对同一音频执行 beam search 语音转录（beam_size=5）以生成 N-best 候选列表（n_best=5），加载语言特定的 wav2vec2 对齐模型进行强制对齐。输出包含词级时间戳和候选转录的 ASR 结果。

Stage 4: VAD AND 时间戳对齐：将 Stage 2 的 Pyannote 语音段与 Stage 3 的 WhisperX 语音段按时间区间进行逻辑 AND 交集操作，仅保留两个 VAD 都标记为语音的区间，合并为包含说话人标签和时间戳的完整 segments 结构。Stage 2 和 Stage 3 的 GPU 模型在此阶段完成后立即卸载。

Stage 5: LLM 三层后处理：在 GPU 模型全部释放后，进入纯 CPU/API 驱动的语义后处理阶段——(5a) 将 segments 按批次发送给 LLM 进行上下文驱动的 ASR 同音字和语义错误修正；(5b) LLM 分析说话人的发言风格和内容主题，生成说话人合并/拆分建议，高置信度合并自动执行；(5c) LLM 为每个 segment 标注 12 类对话行为意图标签，支持多标签输出。

Stage 6: 检索索引构建（可选）：使用纯 Transformer 库加载 BGE-M3 模型，为所有 segments 编码 1024 维稠密向量（CLS token L2 归一化）和稀疏词权重（sparse_linear + ReLU 过滤），稠密向量存入 FAISS IndexFlatIP 索引，稀疏权重序列化为结构化文件。

3.2 核心设计原则

系统的架构设计遵循以下四条核心原则，这些原则贯穿于全部模块的设计和工程决策之中：

原则一：模块化与可替换性。管线的每个阶段对外暴露统一接口，内部实现可独立替换。例如，ASR 后端可在 Whisper-medium（本地）和 Whisper-large-v3（云端）之间切换，LLM 后端可在 DeepSeek、Claude 和 MiniMax 之间切换，且切换对管线其余阶段完全透明。该设计保证了系统在不同硬件条件和部署场景下的灵活适配能力。

原则二：串行执行与 GPU 显存主动管理。所有 GPU 密集型模块严格串行执行，任一时刻 GPU 中只驻留一个模块的模型权重。每个模块处理完成后立即执行显存回收——Python 层的对象引用解除和 PyTorch 层的 CUDA 缓存清空。此机制将 8 GB VRAM（本地 RTX 4060）上的峰值显存使用控制在约 4 GB，16 GB VRAM（云端 T4）上控制在约 8 GB，VRAM 余量始终大于 50%，从根本上避免了 OOM（显存溢出）风险。

原则三：本地/云端双配置分离。系统的运行配置通过 YAML 配置文件实现一键切换。两个配置环境之间的唯一实质性差异在于 ASR 模型选择（本地 Whisper-medium vs. 云端 Whisper-large-v3），其余所有模块使用完全相同模型。此设计确保本地验证通过的功能可无缝迁移至云端全量运行。

原则四：零微调、零标注数据。所有模型权重均使用各模型发布者提供的公开预训练版本，系统未进行任何形式的监督微调、适配训练或领域迁移训练。系统的全部能力来源于管线架构设计（如 VAD AND 对齐）、跨模块工程整合和 LLM 的提示工程驱动语义增强。这意味着系统可以在没有任何领域标注数据的情况下，直接部署到新的应用场景中。

3.3 工程实现的关键挑战与解决方案

本节描述在 Windows 11 + CUDA 12.4 平台上构建本系统时遇到的三个关键工程挑战及其解决方案。

CUDA 库冲突: faster-whisper 的 CTranslate2 推理后端在 Windows 下需要 cuDNN 9 DLL，这些 DLL 由 NVIDIA pip wheel 安装但不在系统 PATH 环境变量中。解决方法是使用 Python 的 DLL 目录注册机制，在导入 CTranslate2 之前主动将 NVIDIA wheel 包的 DLL 路径注册到系统搜索路径。同时，CTranslate2 的导入必须在 Pyannote（通过 onnxruntime 依赖 cuDNN 8）之前完成，以避免两个版本的 cuDNN 在进程中发生初始化冲突。

模型配置路径解析: Pyannote speaker-diarization-3.1 的 pipeline 配置文件(config.yaml) 使用相对路径引用子模型权重（如 segmentation-3.0 的 .bin 文件）。这些相对路径的解析基准是当前进程工作目录而非配置文件所在目录。解决方案是在加载 Pyannote 管线前将工作目录切换到项目根目录，使所有相对路径的解析一致性得到保证。

音频处理库的导入顺序依赖: 在 Windows 平台上，librosa 与 Pyannote 依赖的 SpeechBrain 之间存在底层的 C 扩展导入竞争。如果 Pyannote（通过 SpeechBrain）先于 librosa 导入，librosa 在后续导入时可能因共享 C 扩展库的版本或加载状态冲突而失败。解决方案是强制将 librosa（及其 soundfile 依赖）的导入安排在 Pyannote 相关导入之前完成。

4 关键技术方案

4.1 语音活动检测（VAD）对齐

在多说话人语音转写管线中，说话人分离模块和语音识别模块各自独立运行 VAD 以确定“音频中哪些部分是语音”。这一独立性导致了本系统的第一个核心工程问题：跨模块 VAD 不一致。当 Pyannote 的 segmentation 模型与 WhisperX 的 Silero VAD 对同一时刻的语音/静音判别不一致时，两个模块输出的语音段时间边界存在系统性偏移。这种偏移的直接后果是将说话人分离模块标记的 Speaker ID 与 ASR 识别的文本按时间戳进行简单合并时，说话人 A 的语音内容被错误地归入说话人 B 名下。

本系统提出的 VAD 逻辑 AND 对齐方法用于解决此问题。核心思想是：对于一个时间区间，仅当两个 VAD 都将其判断为“语音”时，该区间的内容才被保留并输出。形式化定义为：

$$\text{Aligned} = \{s_{\text{pyannote}} \cap s_{\text{whisperx}} \mid s_{\text{pyannote}} \in \text{PySegments}, s_{\text{whisperx}} \in \text{WxSegments}, \text{IoU}(s_{\text{pyannote}}, s_{\text{whisperx}}) > \text{threshold}\} \quad (1)$$

其中 IoU (Intersection over Union) 为两个时间区间的交并比指标。实现过程为：遍历 Pyannote 输出的每个说话人片段，逐一计算其与 WhisperX 输出的各 ASR 片段的时间重叠量。(1) 若某 Pyannote 片段与所有 WhisperX 片段均无时间重叠，该片段被丢弃——通常对应 Pyannote 的虚警区间 (VAD 误判为语音的静音或纯音乐段)。(2) 若存在重叠，取两者交集区间作为最终输出 segment 的起止时间，将 Pyannote 的说话人标签和 WhisperX 的转录文本合并到该 segment 中。(3) 若一个 Pyannote 段在时间上与多个 WhisperX 段有重叠 (或多对多的复杂情况)，采用最大 IoU 贪心匹配策略，优先保证高重叠 segments 的正确对齐。

此方法以几乎为零的计算代价 (全对齐阶段耗时 <0.1 秒) 从根本上解决了跨模块时间戳漂移问题。其设计哲学——“取交集而非加权融合或后处理修正”——简单而高效，是本管线中最直接的工程创新。

4.2 端到端说话人分离管线

Pyannote 3.1 的说话人分离管线从原始音频到 RTTM 标注的完整流程如下：

Stage 2a: 语音分段与多说话人检测。Segmentation-3.0 模型采用 SincNet 可学习滤波器组作为前端特征提取器 (相比固定的梅尔滤波器组, SincNet 能自适应地学习适合说话人特征的频域滤波参数)，随后通过多层双向 LSTM 在时间维度上进行逐帧的多标签分类 (每帧可同时属于多个说话人)。模型以 10 秒为窗长在输入音频上滑窗推理 (步长约 1 秒)，输出每个时间帧的帧级语音概率和各说话人的激活分数，包括同时发声的重叠区域。

Stage 2b: 说话人嵌入提取。WeSpeaker 模型 (基于 ResNet-34 架构并在大规模中文说话人识别数据上预训练) 为每个检测到的语音段提取 256 维的固定长度说话人嵌入向量。嵌入空间的几何结构满足类内紧凑性和类间可分性——同一说话人的不同语音段在嵌入空间中聚集紧密，不同说话人的语音段相互远离。这一特性是后续聚类步骤准确性的基础。

Stage 2c: 凝聚层次聚类。以余弦距离为度量，对嵌入向量执行自底向上的凝聚层次聚类 (Agglomerative Hierarchical Clustering)。初始时每个语音段自成一类，逐步合并距离最近的类簇，直至达到预设的距离阈值 (停止条件)。最终每个类簇被赋予一个匿名的 Speaker ID (SPEAKER_00, SPEAKER_01, ...)。完整结果以 RTTM 格式输出。

4.3 语音识别与 N-best 候选生成

系统的 ASR 模块基于 WhisperX 架构，本地部署选用 Whisper-medium（参数量约 769 M），云端部署选用 Whisper-large-v3（参数量约 1.55 B）。Whisper 采用标准的 Transformer 编码器-解码器架构：编码器将 80 通道的 log-Mel 频谱图编码为隐藏状态序列，解码器以自回归方式逐 token 生成输出文本。对于中文场景，输出 token 为字节对编码（BPE）子词单元。

在 Whisper 完成话语级粗粒度转录后，WhisperX 的强制对齐组件（forced alignment）加载预训练的 wav2vec2 对齐模型（中文使用 wav2vec2-large-xlsr-53-chinese-zh-cn）对音频进行帧级对齐。强制对齐的过程为：(1) 使用 Whisper 输出的文本构建发音词典（grapheme-to-phoneme），将文本映射为音素序列；(2) wav2vec2 模型从原始音频波形中提取每 20 ms 一帧的上下文声学特征；(3) 用 CTC 损失在帧级特征和音素序列之间计算最优对齐路径（Viterbi 解码），确定每个 token（进而每个词和字）的精确起止时间。

系统的 beam search 以 beam_size=5 进行解码，保留 5 个得分最高的候选转录路径，形成 N-best 列表。N-best 列表中的不同候选句在 ASR 较不确定的位置（如高噪声帧、同音字帧）各有不同的 token 选择，为后续 LLM 的上下文重打分和纠错提供了多选项空间。

4.4 统一 LLM 语义后处理架构

本系统的 LLM 后处理模块设计遵循统一适配器模式：定义一个抽象接口规定 LLM 交互的核心契约（接收消息列表，返回文本响应），各 LLM 后端的差异（API 协议、认证方式、模型参数）被封装在各自的具体适配器中。系统启动时根据配置自动实例化对应的适配器，业务逻辑层（纠错、一致性、意图）通过统一接口与任意后台进行交互，完全无视后端差异。当前系统支持三个后端：

- DeepSeek：通过 OpenAI 兼容协议接入，中文理解能力强，API 定价极低。
- Claude：通过 Anthropic 原生 SDK 接入，系统提示（system prompt）与对话上下文物理分离，角色扮演和结构化 JSON 输出在复杂任务上最为稳定。
- MiniMax：通过 OpenAI 兼容协议接入，作为国产替代后备方案。

4.4.1 5a 层：上下文驱动的 ASR 纠错

纠错层的工作机制为：将 Stage 4 对齐后产生的完整 segments 按每批 15 段组织为批次，构建结构化的提示发送给 LLM。提示中向 LLM 提供的关键信息包括：(1) 完整的对话上下文（所有 segments 的说话人标签和文本按时间顺序排列）；(2) 每批 15 段中

待纠错的具体文本及其在对话中的位置；(3) 明确的纠错原则——只修正文本内容，不改变时间戳和说话人标签，无错误的段保持原样，修正理由需在 `note` 字段中说明。

LLM 在阅读完整对话上下文后进行批量纠错。其核心推理过程为：基于对话中已建立的讨论主题、各方表达的立场和上下文语义连贯性，判断每句转录是否存在以下类别的错误并提出修正：

- 同音字混淆：声学相似但语义完全不同的汉字替换。
- 数字和专有名词错误：ASR 在数字序列、人名、地名、价格等非自然语言内容上的高频错误。
- 上下文语义矛盾：某句 ASR 输出在语义上与同一说话人此前的立场或对话中已确认的事实相悖。

输出格式为结构化 JSON，每个 segment 对应一个包含 `index`、原始 `text`、修正后 `text` 和可选 `note` 的对象。接收方仅将 `text` 字段替换为 LLM 修正后的版本。

4.4.2 5b 层：说话人一致性交叉验证

一致性检查层的任务是检测 Pyannote 说话人聚类的两类典型错误，利用 LLM 的对话理解能力提供语义层面的辅助判断。

对于过分割检测，LLM 分析被分配不同 Speaker ID 的两个说话人的所有发言，比较以下维度的相似性：(1) 说话风格的稳定性——用词偏好、句法复杂度、填充词频率等文本风格特征；(2) 发言内容的主题连贯性——两个 ID 的发言是否在主题层面有自然的承接关系；(3) 命名实体和指代一致性——不同 ID 是否使用了相同的专有名词或指代词（如都提到了“咱们组的那个项目”）。

对于欠分割检测，LLM 在同一 Speaker ID 的发言序列中查找用词风格或内容主题的突然切换——这种突变可能是两个物理上不同的说话人被错误合并到同一 ID 的信号。

LLM 输出结构化的合并/拆分建议 JSON，每条建议包含：建议操作类型（合并/拆分）、涉及的 Speaker ID、置信度理由、建议执行的置信度评分（0-1）。系统对评估流程的处理策略为：置信度较高的合并建议被自动执行；拆分建议（风险较高）和置信度较低的合并建议被标记为待审查，供用户在后续手动确认。

在实际测试中，该机制成功识别了 Pyannote 1.0 版本的典型错误：将同一说话人的会议开场寒暄（“今天把各位都叫过来啊，咱们讨论一下那个小区…”）与后续的正式议题发言分割到了两个不同的 Speaker ID 之下，LLM 通过识别发言主题的连贯性（“小区”是关键主题词，在寒暄和正式发言中连续出现）和用词风格的一致性给出了合并建议。

4.4.3 5c 层：12 类对话行为意图标注

意图标注层为每个 segment 赋予结构化意图标签，为下游的意图维检索提供元数据基础。本系统定义的 12 类意图标签按四个功能维度组织，具体见表 1。

Table 1: 12 类对话行为意图标签体系

维度	标签	说明
内容型	陈述、提问、提议	话语的核心信息功能：传递信息、获取信息、提出方案
立场型	同意、反对	对他人观点表达赞成或否定的态度
元对话	总结、澄清、确认	对话流程管理和信息校验元操作
话轮社交	命令、打断、寒暄、回应	对话控制（安排任务、插入话轮）和社交礼仪维护

标注过程为：将所有 segments 按说话人和时间顺序组织为对话脚本，发送给 LLM 进行批量意图标注。提示中包含每类意图标签的详细定义、典型例句和标注原则（语境优先于表面词汇、一句话可有多个意图标签等）。LLM 提供的标注信息为对话行为的 12 类标签标出了肯定与否定的结果，同一 segment 可同时拥有多个意图标签。例如，“我同意这个方向，但是预算成本太高了” 这一句话会同时被标注为 [同意, 反对]——先表达同意，后提出基于成本的反对意见。

4.5 BGE-M3 双模检索编码器

本系统的检索编码器完全基于 HuggingFace 的 Transformers 库实现，不依赖 FlagEmbedding、Sentence-Transformers 等第三方高层封装。这一自主实现决策源于 BGE-M3 的 FlagEmbedding 库与 Transformers 4.51+ 之间存在兼容性问题，而 BGE-M3 模型本身所需的底层操作（加载 XLMRobertaModel、前向传播、提取 CLS hidden state 和 token-level hidden states、应用 sparse_linear 层）均可通过 Transformers 库的标准 API 完成。

4.5.1 稠密向量编码

BGE-M3 的稠密向量编码流程为：

- (1) 使用 `AutoModel.from_pretrained` 加载 BGE-M3 的 XLMRobertaModel 基座权重（fp16 半精度以节省显存）。

- (2) 对输入文本进行 tokenization (max_length=8192), 生成 input_ids 和 attention_mask。
- (3) 将 tokenized 输入送入模型进行前向传播, 提取最后一层隐藏状态 (hidden_states, 形状为 [batch_size, seq_len, 1024])。
- (4) 取 CLS token 位置 (序列首位置) 的隐藏状态向量 $h_{CLS} \in \mathbb{R}^{1024}$, 执行 L2 归一化得到单位稠密向量。

所有 segments 的稠密向量被批量编码后存入 FAISS IndexFlatIP (内积索引)。因向量已经 L2 归一化, 内积等价于余弦相似度, 查询时对 query 文本执行相同编码流程, 在 FAISS 索引中搜索 top-k 最近邻向量。

4.5.2 稀疏词权重与词法匹配

BGE-M3 的稀疏词权重编码充分利用了存储于模型目录中的 sparse_linear.pt 文件。该文件是约 3.5 KB 的单层全连接网络权重矩阵 $W_{\text{sparse}} \in \mathbb{R}^{1024 \times 1}$ 。对于文本中每个非特殊 token (排除 [_<s>_, _</s>_, _<pad>_ 及 UNK]) 的隐藏状态 $h_i \in \mathbb{R}^{1024}$, 该 token 的词权重计算为:

$$w_i = \text{ReLU}(W_{\text{sparse}} \cdot h_i) = \max(0, W_{\text{sparse}} \cdot h_i) \quad (2)$$

过滤处理包括: 丢弃特殊 token 对应的权重, 丢弃 ReLU 输出为 0 或负数的权重 (对应模型认为该 token 对词法匹配无贡献), 对同一 token 在文本中的多次出现取最大值 (max-pooling over token positions)。最终每段文本被表示为一个 token-to-weight 的稀疏映射字典。

查询时, query 文本和候选文档的词法匹配得分定义为两者的重叠 token 权重乘积之和:

$$\text{Score}_{\text{lexical}}(Q, D) = \sum_{t \in \text{tokens}(Q) \cap \text{tokens}(D)} w_Q[t] \times w_D[t] \quad (3)$$

4.6 五维异构复合检索与 RRF 融合

检索阶段支持五维独立或组合查询 (表 2), 各维度独立运行后进行 RRF 融合。

Table 2: 五维检索的维度定义、实现机制与权重配置

维度	查询示例	实现机制	RRF 权重
语义	“类似方案不可行的发言”	BGE-M3 稠密向量 + FAISS IndexFlatIP	1.0
关键词	“包含‘预算’的发言”	BGE-M3 稀疏词权重词法匹配	1.0
说话人	“Speaker B 的发言”	元数据精确 ID 过滤	1.5
时间	“后半段的发言”	区间重叠度 + 距离中心衰减	1.0
意图	“所有反对意见”	LLM 预标注意图 any-of 匹配	1.2

多维复合查询的完整检索流程为：

- (1) 解析用户查询字符串，识别其中包含的五维约束（说话人身份、时间范围、意图类别、关键词、语义描述）。
- (2) 若查询包含语义维，对查询文本进行 BGE-M3 稠密编码，在 FAISS 索引中检索 top-k 候选 segments，生成排序列表 R_{semantic} 。
- (3) 若查询包含关键词维，对查询文本进行 sparse_linear 编码，计算其与所有 segments 的词法匹配分数，生成排序列表 R_{lexical} 。
- (4) 在各维度的候选上应用元数据过滤器（说话人精确匹配、时间区间筛查、意图 any-of 过滤），生成过滤后的排序列表 R_{speaker} 、 R_{time} 和 R_{intent} 。
- (5) 将所有非空的排序列表送入 RRF 融合函数，按各维度配置的权重系数计算每个候选 segment 的综合 RRF 得分并降序排列。

5 实验设计

5.1 数据集

实验在两个公开的中文会议数据集的测试子集上展开：

AISHELL-4[27] 全量包含 120 小时录音，211 个会议，每会议 4–8 位参与者，覆盖教育、医疗、科技等真实会议主题。数据以 8 通道麦克风阵列录制，标注信息包括说话人分段时间戳（TextGrid 格式）和说话人身份聚类标注（RTTM 格式）。本研究使用公开测试集的 20 个会议音频，每个音频文件截取前 60 秒用于高效批量评测。

AliMeeting[28] 是为 ICASSP 2022 M2MeT 挑战赛构建的中文会议数据集。全量包含 118.75 小时录音，240 个会议，每会议 2–4 位参与者。音频分为近场（耳麦近距离收音）和远场（房间麦克风远距离收音）两个子集。本研究选用远场子集的 Eval 部分（8 个文件），远场音频因含房间混响和麦克风距离衰减，更接近真实会议场景的声学条件。

此外，本系统还支持在英文数据集上进行验证，包括 VoxConverse (YouTube 影视/演讲片段, 50+ 小时) 和 AMI Meeting Corpus[29] (真实学术会议录音, 约 100 小时)。

5.2 评估指标

说话人分离错误率 (Diarization Error Rate, DER) 由三个可选子指标组成：

- 虚警 (False Alarm, FA)：系统标记为语音但参考标注判定为静音的时间占比。
- 漏检 (Missed Detection, Miss)：参考标注判定为语音但系统未检测到的时间占比。
- 说话人混淆 (Speaker Confusion, Conf)：系统检测到语音但分配给错误说话人 ID 的时间占比。

$DER = FA + Miss + Conf$ 。本研究同时报告原始 DER 和 collar=0.25s 容差窗 DER (说话人边界附近 ± 0.25 秒内的匹配误差不计入错误)。

字符错误率 (Character Error Rate, CER) 使用 jiwer 库的标准实现。需特别说明，由于 60 秒截取窗口的片段级约束以及参考标注的 textgrid (含数百个微小时间片段) 与管线输出 (含少量完整句子级片段) 之间的显著粒度差异，基于全局字符序列对齐的 CER 评测在短窗口内的信度有限，本研究中的 CER 结果主要用于消融趋势的横向对比，而非系统 ASR 精度的绝对标杆。

检索性能覆盖以下指标：FAISS 索引构建耗时、各维度独立查询延迟 (语义编码、说话人过滤、意图过滤) 以及多维度复合查询的总延迟。

5.3 实验配置

为评估 LLM 后处理的效果，设计两组消融对比配置：

E1 基线管线 (无 LLM 后处理)：执行 Stage 2 (说话人分离)、Stage 3 (ASR 与强制对齐)、Stage 4 (VAD AND 对齐)。Stage 1 (Demucs) 在会议数据上关闭，Stage 5 (LLM 后处理) 全部跳过。此配置反映系统的纯声学组件基线性能。

E2 完整管线 (含 LLM 后处理)：执行 Stage 2 至 Stage 5 的全部处理。LLM 后端使用 DeepSeek API 的 deepseek-chat 模型，三层后处理 (纠错、一致性检查、意图标注) 全部启用。Stage 6 (检索索引) 跳过，单独测试。

所有实验在统一环境中运行：Windows 11 × NVIDIA GeForce RTX 4060 Laptop (8 GB VRAM, CUDA 12.4) × PyTorch 2.5.1 × Python 3.10。AISHELL-4 的 20 文件批量评测由自动化评测脚本驱动，每个文件的各阶段处理时间、最终指标和输出 segments 被自动记录为 JSON 评测数据文件。

6 实验结果与分析

6.1 说话人分离性能

表 3 展示了 E1 基线管线和 E2 完整管线在 AISHELL-4 测试集 20 文件上的 DER 对比结果。基线管线的平均 DER 为 45.56% (标准差 23.48%)。

Table 3: AISHELL-4 测试集 DER 评测结果 (20 文件, 各 60 秒截取)

指标	E1 基线 (无 LLM)	E2 完整 (含 LLM)
DER 均值	45.56%	47.67%
DER, collar=0.25s	42.15%	44.01%
DER 最小值	10.74%	10.74%
DER 最大值	100.00%	105.00%
标准差	23.48%	—
文件数量	20	20

引入 collar=0.25s 容差窗后，DER 从 45.56% 降至 42.15% ($\Delta = -3.41$ pp)，表明约 7.5% 的原始 DER 误差集中在说话人切换边界的微小时间偏移 (<0.25 秒)，这些偏移在主观听觉上几乎不可感知，证实 collar 评估在实用场景中更具参考价值。

DER 在文件间的差异极大 (最低 10.74% 至最高 100%)。对这一高方差的分析揭示了三个主要影响因素：(1) 60 秒截取窗口使个别音频文件的截取边界恰好落在说话人切换频率高的对话密集区，此时标注的十毫秒级片段与管线输出的秒级片段在时序尺度上的不匹配被最大化放大了；(2) AISHELL-4 的部分测试文件在进行多通道混合模拟时引入了人工信道效应和去混响处理，这些处理产生的频谱畸变降低了 Pyannote 说话人嵌入的判别力；(3) 说话人数量较多的文件 (6–8 人) 天然的聚类难度远高于 2–4 人文件——聚类空间中的嵌入点随着说话人数增加而密度变大，凝聚层次聚类对距离阈值的敏感度也随之上升。最佳文件 DER=10.74% 对应 2 人清晰对话的最简单场景，验证了管线在最有声条件下的有效性上限。

LLM 一致性检查对 DER 的影响在统计上不显著 (E1 45.56% vs. E2 47.67%，在 $\pm 1\sigma$ 范围内)。这一结果是预期的：LLM 的合并和拆分操作改善的是说话人标注的语义层面一致性 (如同一个人不再被多个匿名 ID 标注，提升了下游分析的准确性)，而非

时间边界层面的对齐精度。标准的 DER 指标仅测量时间和标签的对错，无法捕捉 LLM 说话人一致性修正所引入的语义质量提升。

6.2 语音识别

表 4展示了 CER 的消融对比结果。

Table 4: CER 消融实验结果 (60 秒截取窗口)		
实验配置	平均 CER	CER 变化
E1: 基线 (无 LLM)	59.03%	—
E2: 完整管线 (含 LLM 纠错)	58.80%	−0.23 pp

基线 CER 为 59.03%，这一数值偏高主要归因于三个因素：(1) 60 秒截取窗口内 jiwer 的全局字符串对齐无法妥善处理参考标注的数百个微小片段与管线输出少量长片段之间的粒度假匹配问题；(2) AISHELL-4 标注中包含大量口语化填充词（“嗯”、“啊”、“这个”、“就是说”等）和重叠段的语音，这些内容在 WhisperX 输出中可能被省略或以不同方式呈现；(3) 中文的字符级 CER 天然高于英文的词级 WER——同一处识别错误在英文中可能只影响一个 word，而在中文中却影响多个连续 char。

LLM 纠错使 CER 降低了 0.23 个百分点 (59.03% → 58.80%)，改善幅度虽小但方向正确。LLM 的主要贡献集中在修正同音字混淆和上下文语义矛盾这两类纯声学模型无力处理的错误类型上。在更长的完整音频片段上，LLM 可利用更丰富的对话上下文进行纠错，改善预期更加显著。此外，当前评测的 CER 主导因素是参考-系统输出粒度不匹配而非文本错误，在消除粒度差异后（如采用分段级 CER 逐段计算），LLM 纠错的收益将被更准确地量化。

6.3 管线时序分析

表 5列出了 E1 和 E2 各阶段在 RTX 4060 上的平均处理耗时。

Table 5: 管线各阶段平均处理时间 (60 秒音频, RTX 4060 Laptop 8GB)

管线阶段	E1 基线	E2 完整 (含 LLM)
说话人分离	2.5s	2.4s
语音识别与对齐	5.9s	5.1s
VAD AND 对齐	<0.1s	<0.1s
LLM 后处理 (三层)	—	5.8s
总计	12.4s	16.8s

时序分析的关键发现：

- ASR 阶段 (5.9s) 是 GPU 计算中最耗时的操作，占基线总时间的约 48%。这由 Whisper-medium 的自回归解码特性驱动——生成 token，逐一获取上一 token 的编码器-解码器交叉注意力，在此长序列上呈线性累积延迟。
- LLM 后处理的 5.8s 中，网络往返延迟占多数 (约 70%，~4.0s)，LLM 推理生成时间占少数 (约 30%，~1.8s)。这是因为三层处理需 3 次独立的 API 调用，每次均含完整的网络往返。如果将三层提示合并为单次 API 调用，预计可将 LLM 延迟降至 2.0–2.5s。
- 整体管线对 60 秒音频的 RTF (Real-Time Factor, 处理时间/音频时长) 为：基线 0.21 $\times$ ，完整 0.28 $\times$ 。两者均远低于 1.0 $\times$ 实时阈值的分界线，不仅满足准实时性处理需求，同时留出了向更多时长音频扩展的裕量。

LLM 成本分析。以 30 秒音频 (约 8 个发言段) 的典型三层后处理为例，累计 token 消耗约 2,300 tokens (~1,600 input + ~700 output)。以 DeepSeek 当前 API 定价 (约 ¥1/百万 tokens) 计算，单次处理成本为 ¥0.002。按月处理 1,000 段 30 秒音频核算，月度 LLM 成本仅约 ¥2，属于经济可接受的语义增强费用范围。

6.4 检索系统性能

表 6 展示了以 5 段对话文本构建的检索系统的各项性能指标。

Table 6: BGE-M3 五维检索系统性能 (5 段文本, RTX 4060)

性能指标	实测值
FAISS 索引构建时间	0.29s
索引段数	5
稠密向量维度	1024
平均综合查询延迟	38.3ms
语义查询延迟 (含编码)	86.3ms
说话人过滤延迟	28.9ms
意图过滤延迟	27.4ms

查询延迟在维度间存在清晰分布：纯元数据过滤 (说话人、意图) 耗时 ~28ms，为内存字典查找级别；语义查询耗时 86.3ms，其中 BGE-M3 稠密编码 (tokenization + forward pass) 占 ~55ms，FAISS 内积检索占 ~25ms，网络无关。即使最慢的语义查询 (86.3ms) 仍远低于 200ms 的人机交互体验阈值，呈现近乎即时的主观体验。

在定性功能验证中，复合查询（如“Speaker B 反对预算过高”）被正确解析为说话人过滤（speaker=B）+ 意图过滤（intent= 反对）+ 语义匹配（文本语义相似于“预算过高”）三重独立约束，经 RRF 融合后返回了合理的排序结果。

6.5 定性功能验证

除以上定量评测外，系统三大功能场景分别通过了功能验收：(1) 影视 BGM 鲁棒性场景——上传含背景音乐的影视片段，Demucs 分离后 WhisperX 的转写可懂度有显著提升，验证了前端模块在含噪场景中的必要性；(2) 流式准实时场景——30 秒音频块处理总耗时 <17 秒，实时 Web 界面以 1.5 秒轮询间隔更新转写和 LLM 纠错结果，各说话人的发言按时间线正确排列；(3) 多维检索场景——输入自然语言复合查询，系统正确拆解多维约束，返回排序的检索结果并支持点击跳转音频回放。

7 讨论

7.1 研究发现的意义

本研究展示了一条在标注数据和算力受限条件下的语音处理系统构建路径。通过组合多个公开可用的 SOTA 预训练模型，叠加精心设计的管线架构和轻量级 LLM 语义增强，可以在不进行任何模型微调的情况下构建出覆盖说话人分离、语音识别、语义增强和多维检索的完整系统。这一路径对以下场景具有参考价值：标注数据稀缺的小语种领域、算力资源受限的边缘设备部署环境、以及需要快速原型验证的产学研交叉项目。

VAD AND 对齐策略是最直接的工程成果。以计算代价可忽略（<0.1s）的区间交运算，消除了多说话人管线中普遍存在但长期被低估的时间戳漂移问题。该策略的原理具有一般性——对于任何涉及多个独立 VAD 的语音处理管线，取交集对齐的使用方式可以无需对 VAD 模型进行任何技术改造而直接应用。

LLM 后处理在 CER 上的改善幅度（-0.23 pp）远比在定性功能验证中的效果（同音字修正、说话人合并、意图标注）看起来更加有限。这一矛盾源于当前采用 jiwer 全局字符串对齐的 CER 评测方法会最大化片段粒度不匹配问题在 CER 指标上的干扰效果——当 75% 以上的 CER 来自片段边界对齐误差而非文本内容错误时，LLM 纠错的质量信号被淹没在对齐噪声中。使用分段级逐段 CER，或在完整时长音频（片段粒度不匹配的影响因片段数量增加而稀释）上进行评测，将更准确地反映 LLM 纠错的真实收益。

7.2 局限性与改进方向

实时性与流式能力。当前系统为 30 秒块准实时模式，非逐帧实时处理。对于直播字幕等需要毫秒级首句输出延迟的场景，流式化改造需要将 Whisper 的自回归批量解码替换为流式解码方案（如基于 CTC 的实时 ASR 架构或经过流式蒸馏的 Whisper 变体），这一改造超出了当前工程范围。

说话人识别的匿名性限制。Pyannote 输出的 Speaker ID 只在单文件内有效，无法跨文件关联同一说话人的真实身份。集成独立说话人识别模块（Speaker Identification）以实现从匿名 ID 到注册声纹库中人物身份的跨会话关联，是该系统从会议转录向长期人物追踪演进的关键技术步骤。

检索质量量化的缺失。由于缺乏标准的多说话人语音检索评测基准和带复合查询标注的测试数据，当前检索质量仅通过延迟和功能正确性进行验证。构建一个面向多说话人转写检索的标准化评测集（含 50-100 个复合查询及其相关文档的标注）是推动本领域检索技术进步的基础性工作。

数据集代表性的限制。AISHELL-4 为模拟多通道合成的会议数据集，其声学信道特性与真实现场录制的会议音频存在 gap。在 AMI Corpus[29] 等现场录音数据集以及自采集的真实中文会议音频上进行的迁延性评测，将提供系统在目标部署场景中的更准确性能画像。

语言与对齐模型覆盖。虽然 Whisper 原生支持 99 种语言，但强制对齐所需的高质量 wav2vec2 模型仅覆盖中英两种语言。扩展更多语种的强制对齐能力——通过微调多语言 XLS-R 模型 [9] 或利用 Whisper 自身的编码器-解码器注意力进行跨语言字级对齐——是系统多语言化的重要工程方向。

7.3 未来工作展望

基于当前系统的能力边界和技术债务，后续工作应重点在以下方向突破：

- (1) 对 ASR 模块进行流式化改造，利用 faster-whisper 或其他流式 ASR 方案实现真正的逐帧实时转录，将首句延迟从秒级降至亚秒级。
- (2) 集成基于声纹的说话人识别模块，建立匿名 Speaker ID 与注册声纹库之间的跨会话身份映射机制。
- (3) 构建小规模但可复用的多说话人语音检索评测基准，推动检索质量的量化评估从定性走向定量。
- (4) 扩展强制对齐到更多语种，使系统在 Whisper 覆盖的 99 种语言中至少具备主要语种的字级时间戳对齐能力。

- (5) 在当前三层 LLM 后处理之上，探索利用 LLM 进行对话级摘要生成和关键决策点提取，进一步丰富系统的语义分析能力。

8 结论

本文针对“多说话人语音转写与智能检索”这一具有强应用需求的工程问题，设计并实现了完整的六阶段管线系统。系统以“SOTA 预训练模型 + 工程化管线组合 + LLM 语义增强 + 多维智能检索”为核心技术路线，核心原则是不进行任何模型微调，所有性能提升来源于管线架构设计和语义后处理。

系统的四项核心技术贡献为：(1) 提出了 VAD AND 逻辑交集的时间戳对齐方法，以零计算代价解决了跨模块时间戳漂移问题；(2) 设计了统一 LLM 适配器架构下的三层语义后处理管线，覆盖 ASR 上下文纠错、说话人一致性交叉验证和 12 类对话行为意图多标签标注；(3) 基于纯 Transformer 库实现了 BGE-M3 的稠密向量和稀疏词权重双模编码器，消除了第三方库依赖；(4) 构建了基于 RRF 的五维异构复合检索融合框架，覆盖语义、关键词、说话人、时间和意图全部维度，查询延迟均在 100 毫秒以内。

实验在 AISHELL-4 中文会议数据集上验证了管线的整体有效性：DER 均值为 45.56% (collar=0.25s 下为 42.15%)，管线对 60 秒音频的处理延迟为音频时长的 1/5 至 1/4，检索平均查询延迟为 38.3 毫秒。系统已完整部署于 Windows + RTX 4060 本地环境和 Cloud Studio T4 云端环境，并以 Gradio 交互式图形界面提供用户接口，具备文件转写、浏览器端实时麦克风流式转录和自然语言多维检索三大功能。

本研究证明了“不微调 + 重管线 + LLM 增强”技术路线在多说话人语音转写领域的可行性，可为类似背景下的语音处理系统构建提供方法参考和工程经验。

AI 工具使用声明

本文在撰写过程中使用了 AI 驱动的学术写作辅助工具进行文献检索、结构编排和文字润色工作。所有技术内容和方案设计均由作者独立完成。实验数据采集、处理和分析均由作者通过系统的自动化评测脚本独立执行。文中引用的所有模型、数据集和方法的原始工作归于其各自的作者和发布机构。

References

- [1] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, “Robust speech recognition via large-scale weak supervision,” arXiv preprint arXiv:2212.04356, 2022.
- [2] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, $\boxtimes$. Kaiser, and I. Polosukhin, “Attention is all you need,” Proc. NeurIPS, vol. 30, 2017.
- [3] H. Bredin, “pyannote.audio 2.1 speaker diarization pipeline: Principle, benchmark, and recipe,” in Proc. INTERSPEECH, pp. 1983–1987, 2023.
- [4] H. Bredin and A. Plaquet, “Pyannote.audio 3.x: Speaker diarization with pure PyTorch,” Hugging Face Blog, 2024.
- [5] S. Wang, Z. Chen, H. Wang, C. Liang, B. Zhang, and Y. Qian, “Leveraging large language models for context-aware ASR error correction,” arXiv preprint arXiv:2403.12681, 2024.
- [6] M. Bain, J. Huh, T. Han, and A. Zisserman, “WhisperX: Time-accurate speech transcription of long-form audio,” in Proc. INTERSPEECH, pp. 4489–4493, 2023.
- [7] T. J. Park, N. Kanda, D. Dimitriadis, K. J. Han, S. Watanabe, and S. Narayanan, “A review of speaker diarization: Recent advances with deep learning,” Computer Speech & Language, vol. 72, p. 101317, 2022.
- [8] A. Gulati, J. Qin, C.-C. Chiu, N. Parmar, Y. Zhang, J. Yu, W. Han, S. Wang, Z. Zhang, Y. Wu, and R. Pang, “Conformer: Convolution-augmented transformer for speech recognition,” in Proc. INTERSPEECH, pp. 5036–5040, 2020.
- [9] A. Babu, C. Wang, A. Tjandra, K. Lakhotia, Q. Xu, N. Goyal, K. Singh, P. von Platen, Y. Saraf, J. Pino, A. Baevski, A. Conneau, and M. Auli, “XLS-R: Self-supervised cross-lingual speech representation learning at scale,” arXiv preprint arXiv:2111.09296, 2021.
- [10] Y. Gong, S. Khurana, L. Karlinsky, and J. Glass, “Whisper-AT: Noise-robust automatic speech recognizers are also strong general audio event taggers,” in Proc. INTERSPEECH, 2023.
- [11] B. Zhang, H. Lv, P. Guo, Q. Shao, C. Yang, L. Xie, X. Xu, H. Bu, X. Chen, C. Zeng, D. Wu, and Z. Peng, “WenetSpeech: A 10000+ hours multi-domain

- mandarin corpus for speech research,” arXiv preprint arXiv:2110.03370, 2022.
- [12] Z. Gao, L. Xie, and H. Bu, “Improving mandarin speech recognition with hybrid CTC/Attention architectures and multi-domain training data,” in Proc. ISCSLP, 2022.
 - [13] C. Fan, J. Yi, J. Tao, Z. Tian, B. Liu, and Z. Wen, “Gated recurrent fusion with joint training framework for robust end-to-end speech recognition,” IEEE/ACM Trans. Audio, Speech, Language Process., vol. 29, pp. 198–209, 2021.
 - [14] X. Xiao, N. Kanda, Z. Chen, T. Zhou, T. Yoshioka, S. Chen, Y. Zhao, G. Liu, Y. Wu, J. Wu, S. Liu, and J. Li, “Multi-channel multi-speaker ASR with target-speaker ASR and a joint training system,” in Proc. IEEE ICASSP, 2023.
 - [15] H. Wang, C. Liang, S. Wang, Z. Chen, B. Zhang, X. Xiang, Y. Deng, and Y. Qian, “WeSpeaker: A research and production oriented speaker embedding learning toolkit,” in Proc. IEEE ICASSP, 2023.
 - [16] Z. Huang, X. Wang, and M. Li, “A comparative study of speaker diarization methods for mandarin conference scenarios,” Journal of Signal Processing Systems, 2024.
 - [17] W. Zhang and Y. Qian, “Target-speaker voice activity detection with improved Cross-Attention mechanism,” IEEE Signal Process. Lett., 2023.
 - [18] M. Chen, Y. Su, D. Cai, and Y. Wang, “Large language models for speech and audio: A survey,” arXiv preprint arXiv:2405.15337, 2024.
 - [19] A. Stolcke, K. Ries, N. Coccaro, E. Shriberg, R. Bates, D. Jurafsky, P. Taylor, R. Martin, M. Meteer, and C. V. Ess-Dykema, “Dialogue act modeling for automatic tagging and recognition of conversational speech,” Computational Linguistics, vol. 26, no. 3, pp. 339–373, 2000.
 - [20] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike, and R. Lowe, “Training language models to follow instructions with human feedback,” in Proc. NeurIPS, 2022.

- [21] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, “RoBERTa: A robustly optimized BERT pretraining approach,” in arXiv preprint arXiv:1907.11692, 2019.
- [22] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using siamese BERT-networks,” in Proc. EMNLP-IJCNLP, pp. 3982–3992, 2019.
- [23] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, “BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation,” arXiv preprint arXiv:2402.03216, 2024.
- [24] G. V. Cormack, C. L. A. Clarke, and S. Buettcher, “Reciprocal rank fusion outperforms condorcet and individual rank learning methods,” in Proc. ACM SIGIR, pp. 758–759, 2009.
- [25] A. Défossez, “Hybrid spectrogram and waveform source separation,” in Proc. NeurIPS Workshop on Machine Learning for Audio, 2021.
- [26] S. Rouard, F. Massa, and A. Défossez, “Hybrid transformers for music source separation,” in Proc. IEEE ICASSP, 2023.
- [27] Y. Fu, L. Cheng, S. Lv, Y. Jv, Y. Kong, Z. Chen, Y. Hu, L. Xie, J. Wu, H. Bu, X. Xu, J. Du, and J. Chen, “AISHELL-4: An open source dataset for speech enhancement, separation, recognition and speaker diarization in conference scenario,” in Proc. INTERSPEECH, pp. 3565–3569, 2021.
- [28] F. Yu, S. Zhang, Y. Fu, L. Xie, S. Zheng, Z. Du, W. Huang, P. Guo, Z. Yan, B. Ma, X. Xu, and H. Bu, “M2MeT: The ICASSP 2022 multi-channel multi-party meeting transcription challenge,” in Proc. IEEE ICASSP, pp. 9166–9170, 2022.
- [29] J. Carletta, S. Ashby, S. Bourban, M. Flynn, M. Guillemot, T. Hain, J. Kadlec, V. Karaiskos, W. Kraaij, M. Kronenthal, G. Lathoud, M. Lincoln, A. Lisowska, I. McCowan, W. Post, D. Reidsma, and P. Wellner, “The AMI meeting corpus: A pre-announcement,” Proc. MLMI, pp. 28–39, 2005.